

《企业AI能力中枢—AICoreNexus》

顶层设计(愿景·目标·蓝图)

张子彪

2025-08-10

价值主张

各类模型 统一调度与治理

智能资产 持续沉淀与演进

定位与使命



背景与痛点



能力来源多元且异构

1. 上游包括三类：多家 LLM 供应商、自研 AI 组件（抽取、分类、生成等）、自研或外部传统 ML 模型服务。
2. 协议/鉴权/数据格式/流式能力不一致，集成成本高、上层改造重。



成本与效果难平衡

1. Token/调用成本差异大且波动，缺乏按用户/应用/模型的细粒度成本归集与预算控制。
2. 需要在“成本、延迟、效果”间动态权衡与自动化路由。



复用沉淀不足

1. 提示词工程、行业模板、业务插件难以沉淀与共享，重复造轮子、经验不可迁移。



可观测性与运维割裂

1. 健康、QPS、延迟、错误率、命中率、成本等指标分散在各处，缺少端到端可观测与统一告警。

产品全景

统一入口API

对上REST，对下多源适配

插件化与服务注册

热插拔与动态路由

监控与成本治理

健康/QPS/命中/成本聚合

模型池与路由

标签/等级/健康/QPS/成本

提示词模板中心

集中管理/热加载/复用

前端控制台

仪表盘/配置/发现/历史

六大亮点

01

多模型统一管理

元数据标准化/热加载

02

智能路由

多因素评分/Fallback

03

插件生态

@plugin_api/双入口/并发

04

服务生态

注册即入池/动态代理

05

Prompt中心

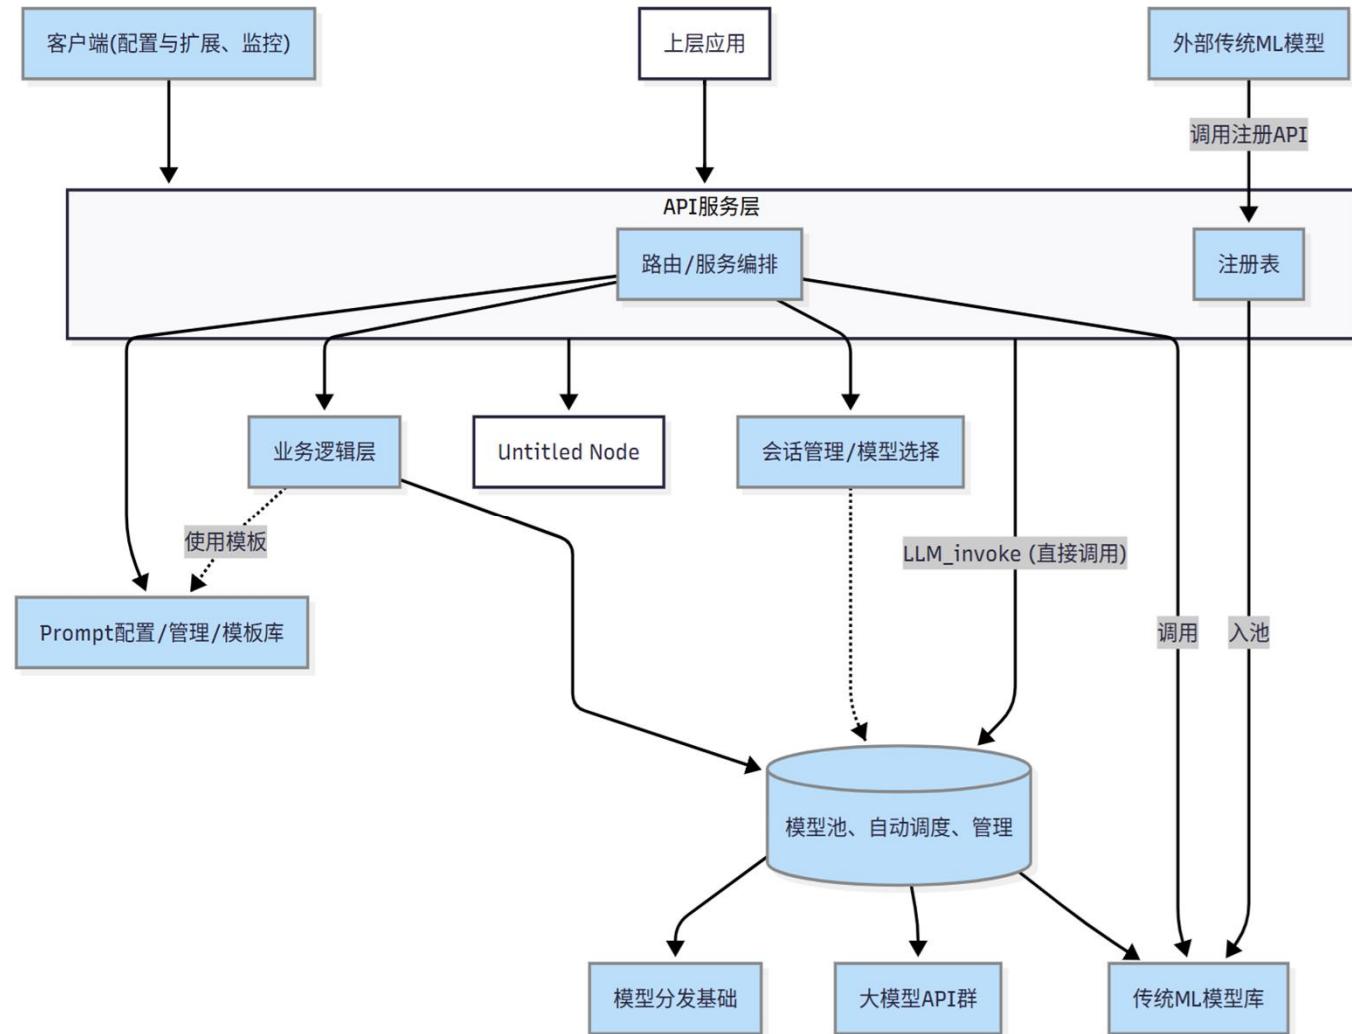
模板沉淀/A-B/热更新

06

可观可管

QPS/健康/成本/历史

总体架构图



关键模块

API服务层

入口/参数/路由/异常

业务逻辑层

会话/选择/批并发

LLM池与路由

状态/选择/限流/健康

插件及服务注册

扫描/注册/热加载

Prompt中心

模板加载/接口/前端

统计与状态

命中/成本/历史/偏好

差异化与 优势

中枢定位

对上治理，对下适配

成本-效果平衡

可配置/可度量

开发者友好

插件/并发/Prompt中心

运维友好

全链路可观测

生态开放

自研+第三方

可演进

策略/架构扩展

路线图

一期

服务发现/插件生态/ /自适应
路由

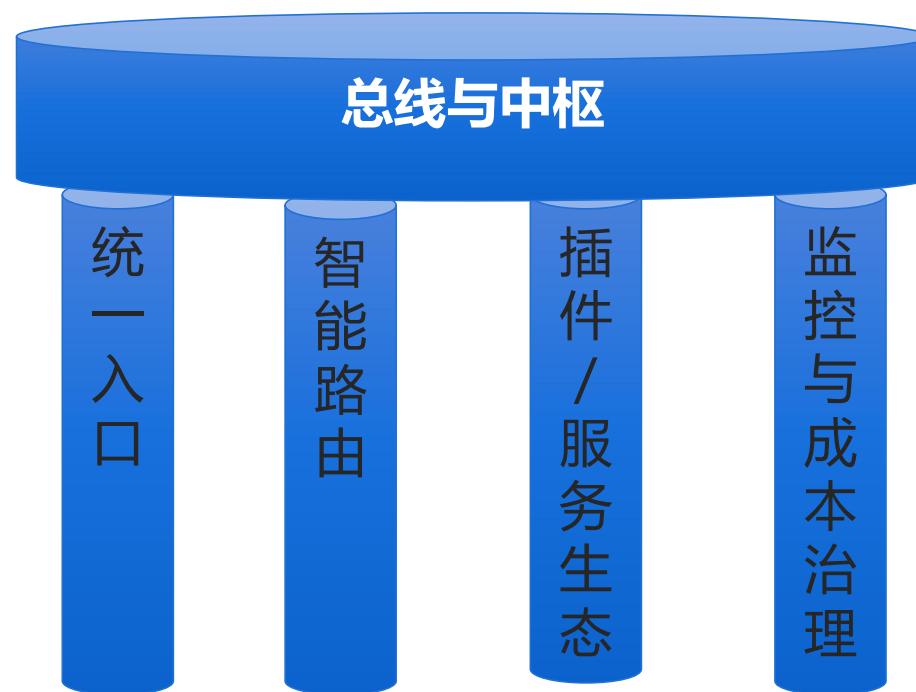
二期

生态市场/安全审计/多租户

总 结

1、四根支柱

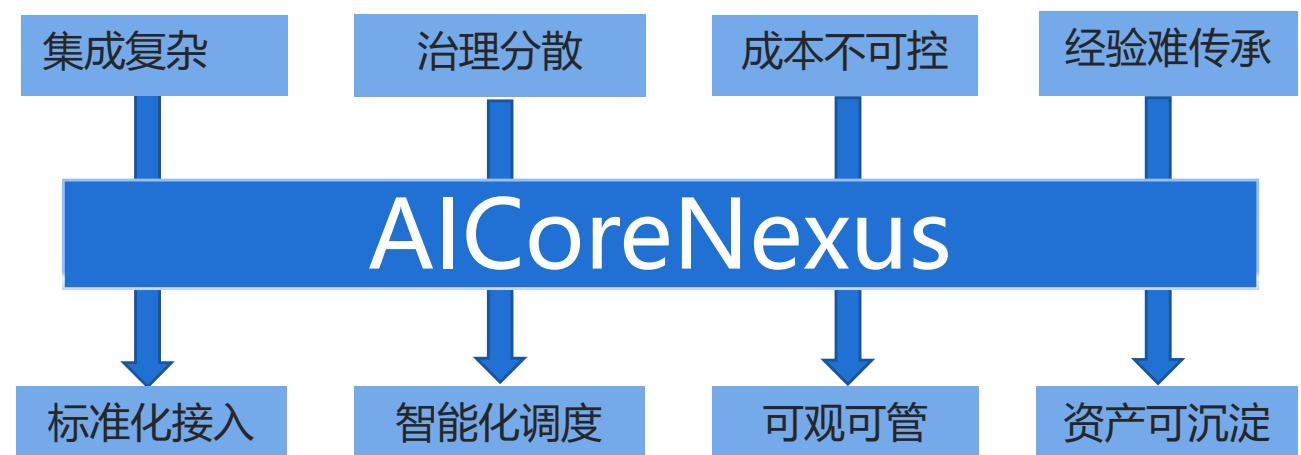
构建企业AI的“总线与中枢

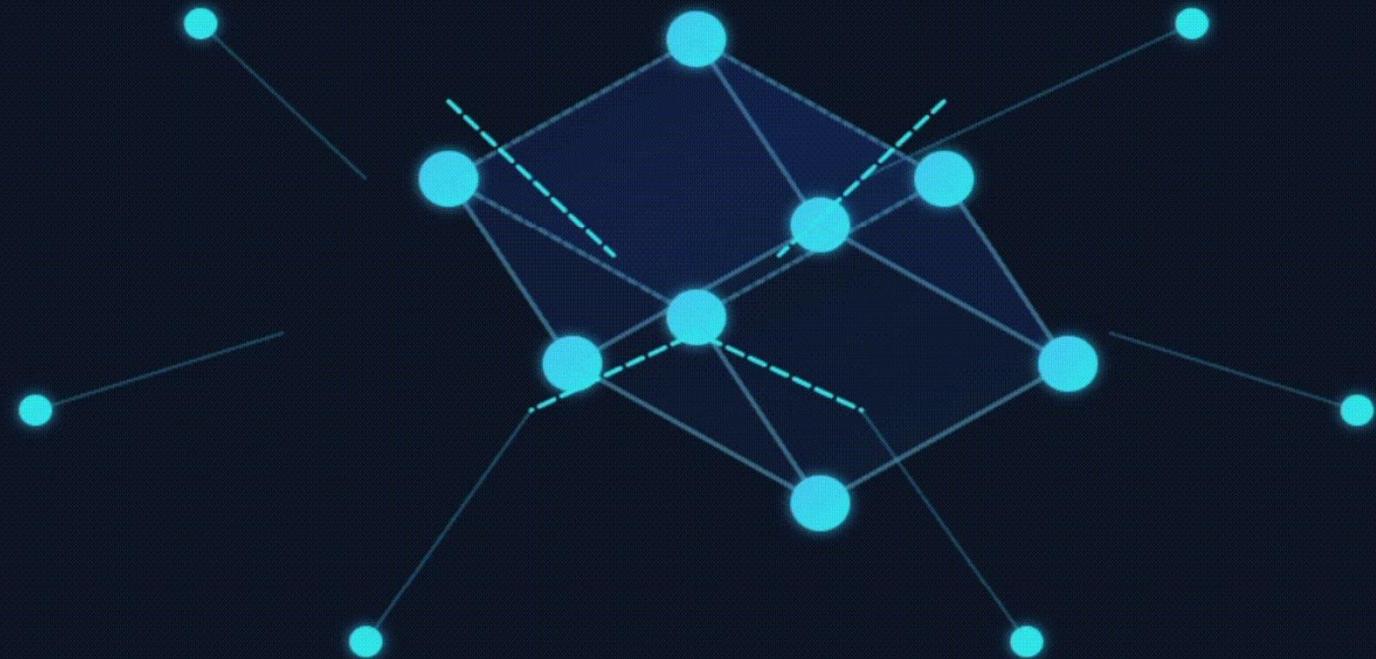


总 结

2、能力中枢

实现从问题到能力的转变





AICoreNexus

Enterprise AI Service Layer